

# Analiza Algorytmów - Projekt

Stawczyk Przemysław 293153

## Contents

<b>1</b>	<b>Opis Zagadnienia</b>	<b>3</b>
1.1	Zadane polecenie	3
1.2	Przykładowe dane wejściowe	3
1.3	Założenia	3
<b>2</b>	<b>Koncepcja Algorytmu</b>	<b>3</b>
2.1	Używane pojęcia	3
2.2	Zarys działania	4
2.3	Złożoność Algorytmu	4
2.3.1	Analiza Złożoności Algorytmu	4
2.3.2	Przyjęta koncepcja pomiarów	4
<b>3</b>	<b>Założenia Implementacyjne</b>	<b>5</b>
3.1	Technologie planowane do wykorzystania	5
3.2	Struktury danych	5
<b>4</b>	<b>Generowanie danych wejściowych</b>	<b>5</b>
4.1	Parametry	5
4.2	Zarys działania	6
<b>5</b>	<b>Opcje Programu</b>	<b>6</b>
5.1	Opcje	6
5.2	Parametry	6
<b>6</b>	<b>Testy i weryfikacja działania</b>	<b>7</b>
6.1	Metodyka	7
6.2	Wizualizacja wyników pod kątem złożoności algorytmu	7
6.2.1	Czas od ilości komentarzy	8
6.2.2	Czas od ilości użytkowników	8
6.2.3	Czas od ilości użytkowników i ilości komentarzy	9
6.3	Analiza wyników pomiarów	9
<b>7</b>	<b>Dokumentacja kodu źródłowego - English</b>	<b>10</b>
7.1	Class Index	10
7.1.1	Class List	10
7.2	Class Documentation	10
7.2.1	Generator Class Reference	10
7.2.2	Detailed Description	10
7.2.3	Constructor & Destructor Documentation	10
7.2.4	Member Function Documentation	11
7.2.5	Solver Class Reference	12

7.2.6 Detailed Description . . . . .	12
7.2.7 Member Function Documentation . . . . .	12

# 1 Opis Zagadnienia

## 1.1 Zadane polecenie

Detektyw Karczoch poszukuje nieuczciwych kont na instagramie. Do tego celu analizuje komentarze dotyczące zamieszczanych zdjęć — wie, że takie konta często walczą między sobą, kupując zwolenników i malkontentów. W komentarzach do takich kont, ludzie z jednej grupy piszą tylko do ludzi z drugiej i odwrotnie. Detektyw Karczoch wie, że zwolennik nigdy nie rozmawia z innym zwolennikiem, a malkontent z malkontentem - to dla nich strata czasu.

*Zadanie : Przygotować program, który na podstawie zamieszczonych komentarzy oceni, czy dane konto jest nieuczciwe.*

## 1.2 Przykładowe dane wejściowe

**Uczciwe :**

#Jan: Piękne zdjęcie.  
#Ola: @Jan Masz rację.  
#Ania: @Ola Nie ma racji!  
#Jan: @Ania właśnie, że mam!  
#Ola: @Ania sama nie masz!

**Nieuczciwe :**

#Jan: Piękne zdjęcie.  
#Ola: @Jan Nieprawda.  
#Jan: @Ola czemu tak twierdzisz?  
#Ania: @Ola no właśnie?  
#Tomek: @Ania twierdzi tak, bo ma rację!!!

## 1.3 Założenia

- Zakładam, że treść komentarza nie ma znaczenia więc dla opisanego celu liczy się jedynie adresat komentarza.
- Zakładam, że pojedynczy komentarz może nie mieć adresata lub mieć dokładnie jednego adresata.
- Zakładam, że istnienie pojedynczych komentarzy od osób które nie adresują do nikogo komentarzy ani nie są adresatami żadnego komentarza nie ma znaczenia dla rozstrzygnięcia uczciwości konta

# 2 Koncepcja Algorytmu

## 2.1 Używane pojęcia

Przy opisie algorytmu stosuje następujące odwzorowanie:

- Każdy komentujący jest reprezentowany przez wierzchołek grafu.

- Komentarz adresowany do innego użytkownika jest reprezentowany przez krawędź w grafie.
- Wiele komentarzy pomiędzy dwoma użytkownikami nie jest odwzorowane jako wielokrotne krawędzie lub krawędzie ważne.  
*Istotny jest fakt komunikacji 2 komentujących, a nie jej objętość*
- Komentarz jest odwzorowany jako krawędź nieskierowana.  
*Istotny jest fakt komunikacji 2 komentujących, a nie który z użytkowników napisał do którego*

## 2.2 Zarys działania

### Opis :

Proponowany algorytm opiera się na założeniu, że istnienie 2 grup [zwolenników i malkontentów], które nie piszą komentarzy wewnątrz swoich grup jest równoznaczne z możliwością podzielenia wierzchołków grafu na 2 części w których nie ma krawędzi [dwudzielność grafu]. Pojedyncze wierzchołki [użytkownicy którzy nie piszą do nikogo, ani nie są adresatami wiadomości] nie mają znaczenia dla rozstrzygnięcia dwudzielności grafu.

### Szkic kroków

- 1 Wczytanie listy komentarzy ze standardowego wejścia lub pliku tworząc graf identyfikowany nazwami użytkowników
- 2 Usunięcie pętli, wierzchołków nieposiadających oraz powtarzających się krawędzi [np poprzez niedodawanie ich do grafu wynikowego]
- 3 Przejście po wierzchołkach "kolorując" je na przeciwne kolory zaczynając od dowolnego niepokolorowanego. Następne wierzchołki brane z kolejki.
  - I Koloruj wierzchołki sąsiednie na przeciwny kolor. Umieść niepokolorowane wcześniej wierzchołki w kolejce do odwiedzenia.
  - II Gdy wierzchołek po drugiej stronie krawędzi jest w tym samym kolorze:  
STOP → *Konto jest uczciwe*.
- 4 Usuń pokolorowane wierzchołki.
- 5 Jeśli graf niepusty: idź do 3 → *Przetwarzanie kolejnego spójnego podgrafu*,  
jeśli pusty: KONIEC → *Konto nie jest uczciwe*

## 2.3 Złożoność Algorytmu

### 2.3.1 Analiza Złożoności Algorytmu

Algorytm iteruje po wszystkich wierzchołkach, a w ramach każdego z wierzchołków po wszystkich jego krawędziach.

Z tego wynika, że złożoność pesymistyczna algorytmu powinna być klasy  $O(V+E)$ , gdzie  $V$  to ilość wierzchołków, a  $E$  ilość krawędzi w grafie.

### 2.3.2 Przyjęta koncepcja pomiarów

Algorytm w przypadku konta uczciwego może zakończyć się wcześniej, więc aby sprawdzać złożoność algorytmu należy mierzyć czasy wykonania analizy nieuczciwych kont. Aby profilować sam algorytm,

mierzony powinien być jedynie czas spędzony na obliczeniach więc będzie on mierzony dopiero po wczytaniu całego grafu z pliku do pamięci.

Dla wybranych wielkości grafu mierzony byłby czas dla kilku danych testowych. Analiza byłaby wykonana osobno ze względu na ilość krawędzi *[przy stałej ilości wierzchołków]*, oraz na ilość wierzchołków *[przy stałej ilości krawędzi, jednak większej od liczby wierzchołków]*.

### 3 Założenia Implementacyjne

#### 3.1 Technologie planowane do wykorzystania

- C++ jako język do implementacji struktury grafu i algorytmu.
- *Mersenne Twister* jako generator liczb losowych na potrzeby generacji danych, implementacja z biblioteki standardowej
- Program do generowania plików z komentarzami zintegrowany z głównym programem
- *boost::chrono* w celu pomiaru czasu spędzonego przez algorytm na procesorze.
- *CMake* jako narzędzie do zarządzania projektem i jego budowaniem
- *doxygen* jako narzędzie do generowania dokumentacji kodu źródłowego

#### 3.2 Struktury danych

- "Node" - jako klasa zawierająca nazwę użytkownika, pole określające kolor, identyfikowana przez numer pozycji w dynamicznej tablicy  
*W Node : vector<int> - przechowuje wierzchołki sąsiednie.*  
*W Node : enum "Kolor" - określa czy wierzchołek był odwiedzony oraz kolor odwiedzzonego wierzchołka.*
- map<String, int> - zapewniająca odwzorowanie nazwy użytkownika na pozycję w tablicy  
*Pomocniczo przy wczytywaniu grafu*
- vector<Node> - kontener przechowujący wierzchołki  
*Zapewnia dostęp do wierzchołka poprzez numer*
- list<int> - przechowuje listę wierzchołków do odwiedzenia, umieszczane są w niej kolejni nieodwiedzeni sąsiedzi przetwarzanego wierzchołka

### 4 Generowanie danych wejściowych

#### 4.1 Parametry

- liczebność wierzchołków w grafie lub liczebność obu grup z osobna
- liczebność krawędzi w grafie
- uczciwość konta
- nazwa pliku wyjściowego

## 4.2 Zarys działania

Przy generowaniu danych w pierwszym kroku tworzone są 2 grupy wierzchołków o podanych licznosciach lub wedle losowego podziału jednej liczby na wejściu. Następnie tworzone są krawędzie *[komentarze]* poprzez losowanie po jednym wierzchołku z każdej grupy. W przypadku zadania parametrem uczciwości konta dodawane są w małej liczbie krawędzie w obrębie grup stworzonych wcześniej. Jako ostatni etap występuje zapis danych do pliku gdzie dla każdej krawędzi podstawiane są nazwy użytkowników oraz format linii *[dla uwiarygodnienia danych wyjściowych]*.

### Struktury danych

- String - *przechowuje linię komentarza zakończoną znakiem nowej linii lub login użytkownika*
- vector<String> - *kontener przechowujący loginy użytkowników*
- vector<String> - *kontener przechowujący komentarze użytkowników*

## 5 Opcje Programu

### 5.1 Opcje

Program umożliwia profilowanie algorytmu, generowanie oraz rozwiązywanie problemów.

W przypadku podania wielu opcji profilowanie ma największy priorytet, następnie generowanie problemów. Natomiast rozwiązywanie problemów jest wykonywane w przypadku nie podania innych opcji.

W przypadku podania rozmiaru jednej z grup równego 0 rozmiary grup są każdorazowo losowane.

### 5.2 Parametry

- -h [ -help ] - ekran z objaśnieniami
- -o [ -output ] - plik wyjściowy dla generowanych problemów [przy braku problem jest wypisywany na stdout]
- -i [ -input ] - plik wejściowy do analizy
- -iter arg (=1) - liczba iteracji przy profilowaniu algorytmu
- -p [ -profiling ] - określa czy algorytm ma być profilowany
- -g [ -generating ] - określa czy ma zostać wygenerowany problem
- -c [ -comments\_count (=10) ] - całkowita liczba komentarzy [dla generowanych problemów]
- - -users\_count (=5) - całkowita liczba użytkowników [dla generowanych problemów]
- - -group\_count - licznosc jednej z grup [ma znaczenie przy generowaniu uczciwych problemów]
- -f [ -fairness ] - [dla generowanych problemów]

## 6 Testy i weryfikacja działania

### 6.1 Metodyka

Czas wykonania algorytmu był mierzony po wczytaniu oraz przygotowaniu grafu a pomocą biblioteki *boost::chrono* obliczając odległość pomiędzy początkiem a końcem algorytmu. Zgodnie z wcześniej przyjętym założeniem mierzone były jedynie problemy dające wynik nieucieczny by badać pesymistyczną złożoność algorytmu. Testy zostały przeprowadzone poprzez skorzystanie z trybu profilowania stworzonego programu, dla każdej pary: *ilości użytkowników i komentarzy* dokonano 100 wykonań algorytmu przyjmując do dalszej analizy wartość średnią dzięki czemu wszelkie wstępne opóźnienia pierwszych wykonań zmniejszają swój wpływ na wynik. Pomiarów dokonano na nieobciążonej innymi zadaniami maszynie stacjonarnej obciążając 1 z 6 dostępnych rdzeni procesora by wpływ działającego systemu był minimalny.

Wykonano pomiary dla liczności użytkowników :

*250 500 750 1000 2500 5000 7500 10000 25000*

i liczności komentarzy:

*250 500 750 1000 2500 5000 7500 10000 25000 50000 100000 250000 500000 1000000 2500000 5000000.*

Zachowując realizm testowano dla liczby komentarzy co najmniej równej ilości użytkowników oraz dla największych liczb komentarzy [*2500000 od 2500 użytkowników wzwyż, 5000000 od 5000*]

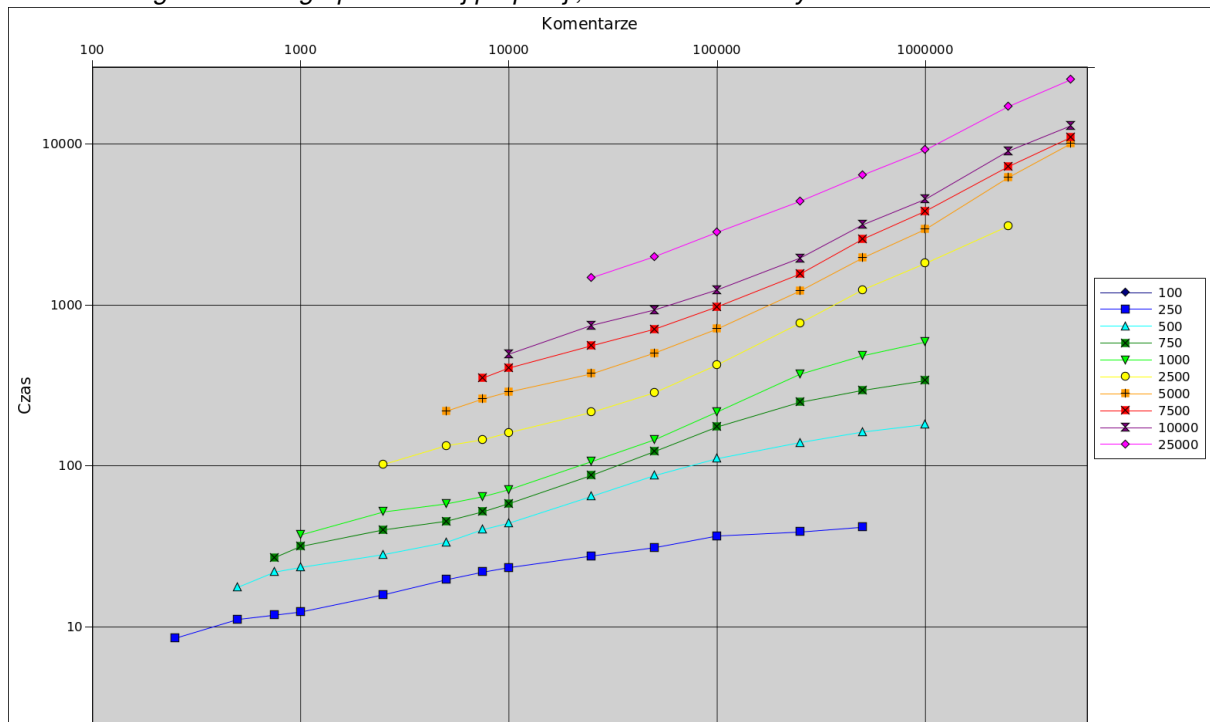
Pewien wpływ na wyniki dla dużych ilości komentarzy może mieć fakt, że wiele komentarzy pomiędzy 2 użytkownikami jest interpretowane jako jedna krawędź.

Ze względu na różnice wartości liczby użytkowników [*wierzchołków - V*] oraz komentarzy [*krawędzi - E*] zastosowano skalę logarytmiczno-logarytmiczną na wykresach.

### 6.2 Wizualizacja wyników pod kątem złożoności algorytmu


### 6.2.1 Czas od ilości komentarzy

*Dla ustalonego rozmiaru grup o losowej proporcji, średnia dla 100 wykonań*



### 6.2.2 Czas od ilości użytkowników


*Dla ustalonej ilości komentarzy, dla grup o losowej proporcji, średnia dla 100 wykonań*





### 6.2.3 Czas od ilości użytkowników i ilości komentarzy

Prezentacja "górnej" części danych w celu zapewnienia większej czytelności



## 6.3 Analiza wyników pomiarów

Przed interpretacją wyników należy zwrócić uwagę na efekt mający wpływ na zmniejszenie czasu obliczeń. Generowania problemów nie uwzględnia tworzenia nieunikalnych połączeń pomiędzy użytkownikami [może wystąpić kilka połączeń pomiędzy 2] które jest niwelowane po wczytaniu problemu do algorytmu skutkując mniejszym rzeczywistym rozmiarem problemu.

Wyniki testów zostały poddane analizie w programie *gnumeric* czego efektem są powyższe wykresy. Ponadto trójki wartości  $[liczba\ użytkowników][liczba\ komentarzy][czas]$  zostały poddane regresji liniowej. Dla regresji wszystkich wartości współczynnik korelacji pomiędzy ilością komentarzy, a czasem  $[miarą\ złożoności\ problemu]$  wynosi :  $0.93$  co można uznać za złożoność  $O(E)$  względem liczby krawędzi  $E$ . Wniosek ten potwierdza obserwacja wykresu.

Dla liczności grupy sytuacja jest nieco bardziej złożona ponieważ korelacja dla całego zbioru wartości wynosi  $0.66$  co nie dowodzi zależności liniowej. Jednak obserwując wykres widzimy, że dla odpowiednio dużych wartości stopniowo wypłaszcza się i ma skośną asymptotę liniową.

Ponieważ zależność pomiędzy złożonością a  $E$  i  $V$  jest liniowa to wynikowa złożoność może przedstawiać się jako  $O(V \cdot E)$  lub  $O(V+E)$ . Analiza z użyciem regresji liniowej dla 2 zmiennych, próbek o liczbie użytkowników większej od 250 daje zbieżność na poziomie  $0.97$

Podsumowując: przeprowadzony eksperyment dowodzi, że zaproponowany algorytm ma pesymistyczna złożoność  $O(V+E)$

## 7 Dokumentacja kodu źródłowego - English

### 7.1 Class Index

#### 7.1.1 Class List

Here are the classes, structs, unions and interfaces with brief descriptions:

<b>Generator</b>	
Class for problem instances generation	<b>10</b>
<b>Solver</b>	
Class created to solve problem instances	<b>12</b>

### 7.2 Class Documentation

#### 7.2.1 Generator Class Reference

**Generator** class for problem instances generation.

```
#include <Generator.h>
```

#### Public Member Functions

- **Generator** (std::initializer\_list< string > names\_list=NAMES\_\_ALL)  
*Constructor for the generator.*
- std::stringstream **generate\_instance\_output** (bool fair, uint64\_t users\_count, uint64\_t l\_group\_count, uint64\_t comments\_count)  
*Generates problem instance according to parameters as a stream.*
- std::stringstream **generate\_instance\_output** (vector< string > &problem\_instance)  
*Creates printable stream from a vector of lines.*
- vector< string > **generate\_instance** (bool fair, uint64\_t users\_count, uint64\_t l\_group\_count, uint64\_t comments\_count)  
*Generates problem instance according to parameters as a vector of lines.*

#### 7.2.2 Detailed Description

**Generator** class for problem instances generation.

#### 7.2.3 Constructor & Destructor Documentation

```
Generator() Generator::Generator (
    std::initializer_list< string > names_list = NAMES__ALL )
```

Constructor for the generator.

Wraps random number generator and basic list of names for login creation. Stateless excluding RNG state.

#### Parameters

<i>names_list</i>	list of names to be used, default is list of polish names from wikipedia.org
-------------------	--

## 7.2.4 Member Function Documentation

```
generate_instance() vector< string > Generator::generate_instance (
    bool fair,
    uint64_t users_count,
    uint64_t l_group_count,
    uint64_t comments_count )
```

Generates problem instance according to parameters as a vector of lines.

#### Parameters

<i>fair</i>	determine if account should be fair or not
<i>users_count</i>	count of all users
<i>l_group_count</i>	count of one of the "groups" commenting
<i>comments_count</i>	number of comments

#### Returns

problem instance in a vector

```
generate_instance_output() [1/2] std::stringstream Generator::generate_instance_output (
    bool fair,
    uint64_t users_count,
    uint64_t l_group_count,
    uint64_t comments_count )
```

Generates problem instance according to parameters as a stream.

#### Parameters

<i>fair</i>	determine if account should be fair or not
<i>users_count</i>	count of all users
<i>l_group_count</i>	count of one of the "groups" commenting
<i>comments_count</i>	number of comments

## Returns

problem instance in a stream

```
generate_instance_output() [2/2]  std::stringstream Generator::generate_instance_output (
    vector< string > & problem_instance )
```

Creates printable stream from a vector of lines.

## Parameters

<i>problem_instance</i>	problem instance
-------------------------	------------------

## Returns

problem instance in a stream

## 7.2.5 Solver Class Reference

class created to solve problem instances

```
#include <Solver.h>
```

## Public Member Functions

- bool [is\\_fair](#) (std::vector< std::string > &problem\_instance, uint64\_t &time)  
*loads problem instance to the object and runs check*
- bool [is\\_fair](#) (std::stringstream &problem\_instance, uint64\_t &time)  
*loads problem instance to the object and runs check*

## 7.2.6 Detailed Description

class created to solve problem instances

## 7.2.7 Member Function Documentation

```
is_fair() [1/2]  bool Solver::is_fair (
    std::vector< std::string > & problem_instance,
    uint64_t & time )
```

loads problem instance to the object and runs check

## Parameters

<i>problem_instance</i>	problem instance as a vector of lines
<i>time</i>	reference to which time elapsed will be added

## Returns

result : if account is fair

```
is_fair() [2/2] bool Solver::is_fair (
    std::stringstream & problem_instance,
    uint64_t & time )
```

loads problem instance to the object and runs check

## Parameters

<i>problem_instance</i>	problem instance as a stream containing lines
<i>time</i>	reference to which time elapsed will be added

## Returns

result : if account is fair