Analiza Algorytmów - Projekt

Stawczyk Przemysław 293153

Contents

1 Opis Zagadnienia

1.1 Zadane polecenie

Detektyw Karczoch poszukuje nieuczciwych kont na instagramie. Do tego celu analizuje komentarze dotyczące zamieszczanych zdjęć — wie, że takie konta często walczą między sobą, kupując zwolenników i malkontentów. W komentarzach do takich kont, ludzie z jednej grupy piszą tylko do ludzi z drugiej i odwrotnie. Detektyw Karczoch wie, że zwolennik nigdy nie rozmawia z innym zwolennikiem, a malkontent z malkontentem - to dla nich strata czasu.

Zadanie : *Przygotować program, który na podstawie zamieszczonych komentarzy oceni, czy dane konto jest nieuczciwe.*

1.2 Przykładowe dane wejściowe

Uczciwe :
#Jan: Piękne zdjęcie.
#Ola: @Jan Masz rację.
#Ania: @Ola Nie ma racji!
#Jan: @Ania właśnie, że mam!
#Ola: @Ania sama nie masz!

Nieuczciwe :
#Jan: Piękne zdjęcie.
#Ola: @Jan Nieprawda.
#Jan: @Ola czemu tak twierdzisz?
#Ania: @Ola no właśnie?
#Tomek: @Ania twierdzi tak, bo ma rację!!!

1.3 Założenia

- Zakładam, że treść komentarza nie ma znaczenia więc dla opisanego celu liczy się jedynie adresat komentarza.
- Zakładam, że pojedynczy komentarz może nie mieć adresata lub mieć dokładnie jednego adresata.
- Zakładam, że istnienie pojedynczych komentarzy od osób które nie adresują do nikogo komentarzy ani nie są adresatami żadnego komentarza nie ma znaczenia dla rozstrzygnięcia uczciwości konta

2 Koncepcja Algorytmu

2.1 Używane pojęcia

Przy opisie algorytmu stosuje następujące odwzorowanie:

- Każdy komentujący jest reprezentowany przez wierzchołek grafu.

- Komentarz adresowany do innego użytkownika jest reprezentowany przez krawędź w grafie.
- Wiele komentarzy pomiędzy dwoma użytkownikami **nie** jest odwzorowane jako wielokrotne krawędzie lub krawędzie ważone.
  Istotny jest fakt komunikacji 2 komentujących, a nie jej objętość
- Komentarz jest odwzorowany jako krawędź nieskierowana.
  Istotny jest fakt komunikacji 2 komentujących, a nie który z użytkowników napisał do którego

2.2 Zarys działania

Opis :

Proponowany algorytm opiera się na założeniu, że istnienie 2 grup *[zwolenników i malkontentów]*, które nie piszą komentarzy wewnątrz swoich grup jest równoznaczne z możliwością podzielenia wierzchołków grafu na 2 części w których nie ma krawędzi *[dwudzielność grafu]*.
Pojedyncze wierzchołki*[użytkownicy którzy nie piszą do nikogo, ani nie są adresatami wiadomości]* nie mają znaczenia dla rozstrzygnięcia dwudzielności grafu.

Szkic kroków

1. Wczytanie listy komentarzy ze standardowego wejścia lub pliku.
2. Z problemu tworzony jest graf identyfikowany nazwami użytkowników
3. Usunięcie pętli [połączeń z wierzchołka do niego samego], wierzchołków nieposiadających oraz powtarzających się krawędzi [np poprzez niedodawanie ich do grafu wynikowego]
4. Przejście po wierzchołkach "kolorując" je na przeciwne kolory zaczynając od dowolnego niepokolorowanego. Następne wierzchołki brane z kolejki.
   I. Koloruj wierzchołki sąsiednie na przeciwny kolor. Umieść niepokolorowane wcześniej wierzchołki w kolejce do odwiedzenia.
   II. Gdy wierzchołek po drugiej stronie krawędzi jest w tym samym kolorze:
   Znaleziono nieparzysty cykl w grafie co jest równoznaczne z faktem, że graf nie jest dwudzielny
   STOP –> *Konto jest uczciwe.*
5. Usuń pokolorowane wierzchołki.
6. Jeśli graf niepusty: idź do 3 –> *Przetwarzanie kolejnego spójnego podgrafu*,
   jeśli pusty:
   Udało się pokolorować graf kolorowaniem dwubarwnym wiec jest on dwudzielny.
   KONIEC –> *Konto nie jest uczciwe*

2.3 Złożoność Algorytmu

2.3.1 Analiza Złożoności Algorytmu

Algorytm iteruje po wszystkich wierzchołkach, a w ramach każdego z wierzchołków po wszystkich jego krawędziach.
Z tego wynika, że złożoność pesymistyczna algorytmu powinna być klasy *O(V+E)*, gdzie *V* to ilość wierzchołków, a *E* ilość krawędzi w grafie.

2.3.2 Przyjęta koncepcja pomiarów

Algorytm w przypadku konta uczciwego może zakończyć się wcześniej, więc aby sprawdzać złożoność algorytmu należy mierzyć czasy wykonania analizy nieuczciwych kont. Aby profilować sam algorytm, mierzony powinien być jedynie czas spędzony na obliczeniach więc będzie on mierzony dopiero po wczytaniu całego grafu z pliku do pamięci.

Dla wybranych wielkości grafu mierzony byłby czas dla kilku danych testowych. Analiza byłaby wykonana osobno ze względu na ilość krawędzi *[przy stałej ilości wierzchołków]*, oraz na ilość wierzchołków *[przy stałej ilości krawędzi, jednak większej od liczby wierzchołków]*.

3 Założenia Implementacyjne

3.1 Technologie planowane do wykorzystania

- *C++* jako język do implementacji struktury grafu i algorytmu.
- *Mersenne Twister* jako generator liczb losowych na potrzeby generacji danych, implementacja z biblioteki standardowej
- Program do generowania plików z komentarzami zintegrowany z głównym programem
- *boost::chrono* w celu pomiaru czasu spędzonego przez algorytm na procesorze.
- *CMake* jako narzędzie do zarządzania projektem i jego budowaniem

3.2 Struktury danych

- "Node" - *jako klasa zawierająca nazwę użytkownika, pole określające kolor, identyfikowana przez numer pozycji w dynamicznej tablicy*

  W Node : vector<int> - *przechowuje wierzchołki sąsiednie.*

  W Node : enum "Kolor" - *określa czy wierzchołek był odwiedzony oraz kolor odwiedzonego wierzchołka.*
- map<String, int> - *zapewniająca odwzorowanie nazwy użytkownika na pozycję w tablicy*
  Pomocniczo przy wczytywaniu grafu
- vector<Node> - *kontener przechowujący wierzchołki*
  Zapewnia dostęp do wierzchołka poprzez numer
- list<int> - *przechowuje listę wierzchołków do odwiedzenia, umieszczane są w niej kolejni nieodwiedzeni sąsiedzi przetwarzanego wierzchołka*

4 Generowanie danych wejściowych

4.1 Parametry

- liczebność wierzchołków w grafie lub liczebność obu grup z osobna
- liczebność krawędzi w grafie

- uczciwość konta
- nazwa pliku wyjściowego

4.2 Zarys działania

Przy generowaniu danych w pierwszym kroku tworzone są 2 grupy wierzchołków o podanych licznościach lub wedle losowego podziału jednej liczby na wejściu. Następnie tworzone są krawędzie *[komentarze]* poprzez losowanie po jednym wierzchołku z każdej grupy. W przypadku zadania parametrem uczciwości konta dodawane są w małej liczbie krawędzie w obrębie grup stworzonych wcześniej. Jako ostatni etap występuje zapis danych do pliku gdzie dla każdej krawędzi podstawiane są nazwy użytkowników oraz format linii *[dla uwiarygodnienia danych wyjściowych]*.

Struktury danych

- String - *przechowuje linię komentarza zakończoną znakiem nowej linii lub login użytkownika*
- vector<String> - *kontener przechowujący loginy użytkowników*
- vector<String> - *kontener przechowujący komentarze użytkowników*

5 Opcje Programu

5.1 Opcje

Program umożliwia profilowanie algorytmu, generowanie oraz rozwiązywanie problemów.

W przypadku podania wielu opcji profilowanie ma największy priorytet, następnie generowanie problemów. Natomiast rozwiązywanie problemów jest wykonywane w przypadku nie podania innych opcji.

W przypadku podania rozmiaru jednej z grup równego 0 rozmiary grup są każdorazowo losowane.

5.2 Parametry

- *-h [- -help]* - ekran z objaśnieniami
- *-m [–mode]* - tryb działania programu [1 = rozwiązywanie, 2 = generacja, 3 = profilowanie]
- *-o [- -output]* - plik wyjściowy dla generowanych problemów [przy braku problem jest wypisywany na stdout]
- *-i [- -input]* - plik wejściowy do analizy [przy braku problem jest pobierany z stdin]
- *–iter arg (=1)* - liczba iteracji przy profilowaniu algorytmu
- *-c [- -comments_count (=10)]* - całkowita liczba komentarzy [dla generowanych problemów]
- *- -users_count (=5)* - całkowita liczba użytkowników [dla generowanych problemów]
- *- -group_count* - liczność jednej z grup [ma znaczenie przy generowaniu uczciwych problemów]
- *-f [- -fairness]* - [dla generowanych problemów]

- *-s [- -seed (=0)]* - ziarno dla generatora liczb losowych [jesli = 0, RNG domyslny dla platformy generuje ziarno]

6 Testy i weryfikacja działania

6.1 Metodyka

Czas wykonani algorytmu był mierzony po wczytaniu oraz przygotowaniu grafu a pomocą biblioteki *boost::chrono* obliczając odległość pomiędzy początkiem a końcem algorytmu. Zgodnie z wcześniej przyjętym założeniem mierzone były jedynie problemy dające wynik nieuczciwy by badać pesymistyczną złożoność algorytmu. Testy zostały przeprowadzone poprzez skorzystanie z trybu profilowania stworzonego programu, dla każdej pary: *ilości użytkowników i komentarzy* dokonano 100 wykonań algorytmu przyjmując do dalszej analizy wartość średnią dzięki czemu wszelkie wstępne opóźnienia pierwszych wykonań zmniejszają swój wpływ na wynik. Pomiarów dokonano na nieobciążonej innymi zadaniami maszynie stacjonarnej obciążając 1 z 6 dostępnych rdzeni procesora by wpływ działającego systemu był minimalny.

Wykonano pomiary dla liczności użytkowników :
250 500 750 1000 2500 5000 7500 10000 25000
i liczności komentarzy:
250 500 750 1000 2500 5000 7500 10000 25000 50000 100000 250000 500000 1000000 2500000 5000000.
Zachowując realizm testowano dla liczby komentarzy co najmniej równej ilości użytkowników oraz dla największych liczb komentarzy *[2500000 od 2500 użytkowników wzwyż, 5000000 od 5000]*
Pewien wpływ na wyniki dla dużych ilości komentarzy może mieć fakt, że wiele komentarzy pomiędzy 2 użytkownikami jest interpretowane jako jedna krawędź.

Ze względu na różnice wartości liczby użytkowników *[wierzchołków - V]* oraz komentarzy *[krawędzi - E]* zastosowano skalę logarytmiczno-logarytmiczną na wykresach.

6.2 Wizualizacja wyników pod kątem złożoności algorytmu

6.2.1 Czas od ilości komentarzy

Dla ustalonego rozmiaru grup o losowej proporcji, średnia dla 100 wykonań

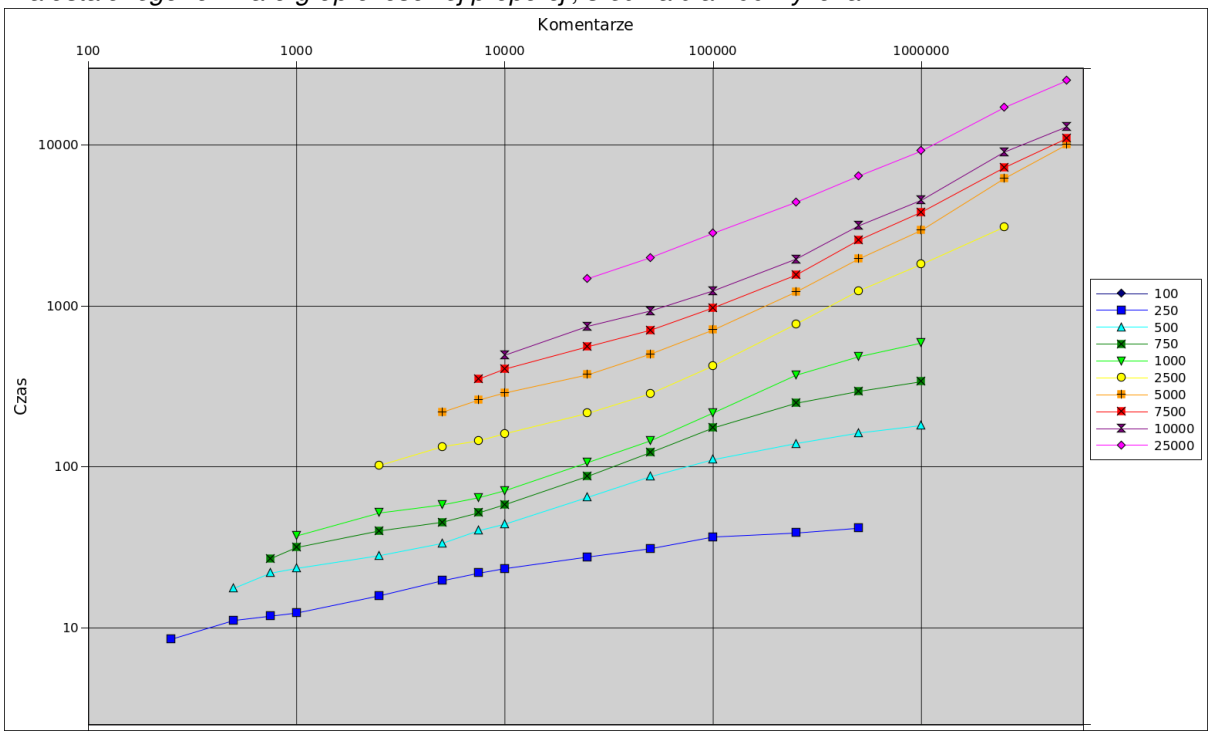

6.2.2 Czas od ilości użytkowników

Dla ustalonej ilości komentarzy, dla grup o losowej proporcji, średnia dla 100 wykonań

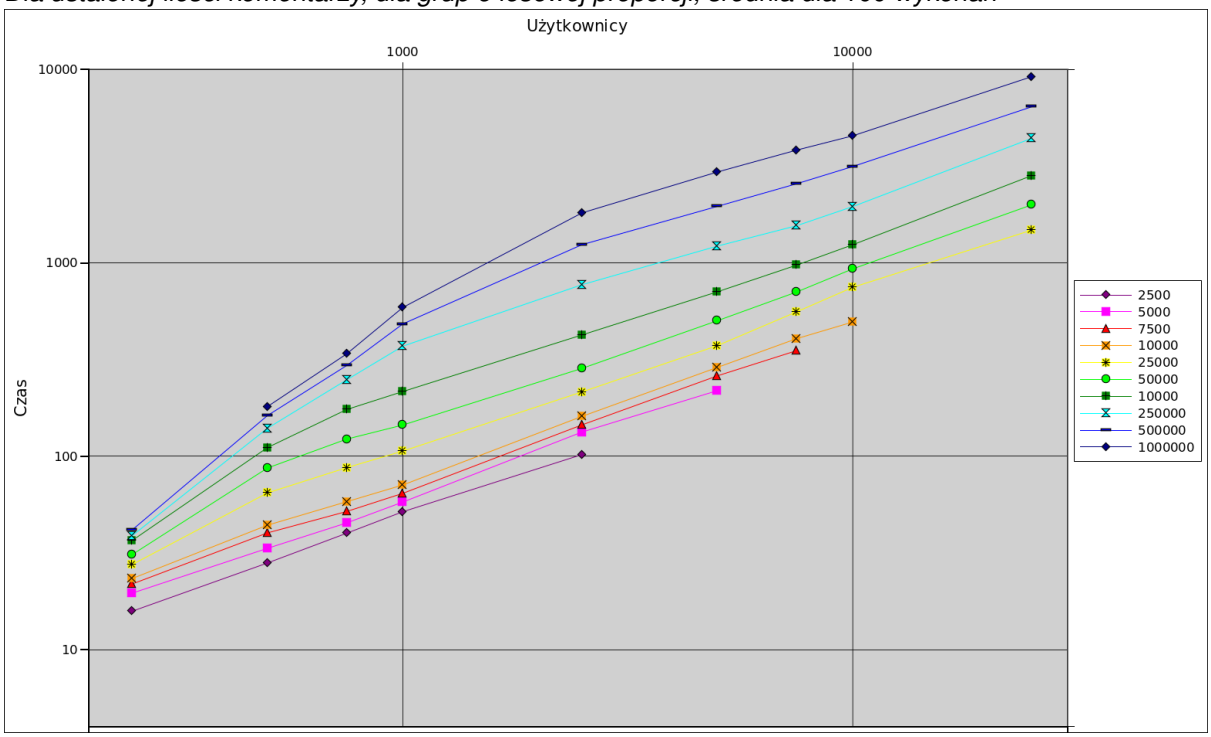

6.2.3 Czas od ilości użytkowników i ilości komentarzy

Prezentacja "górnej" części danych w celu zapewnienia większej czytelności

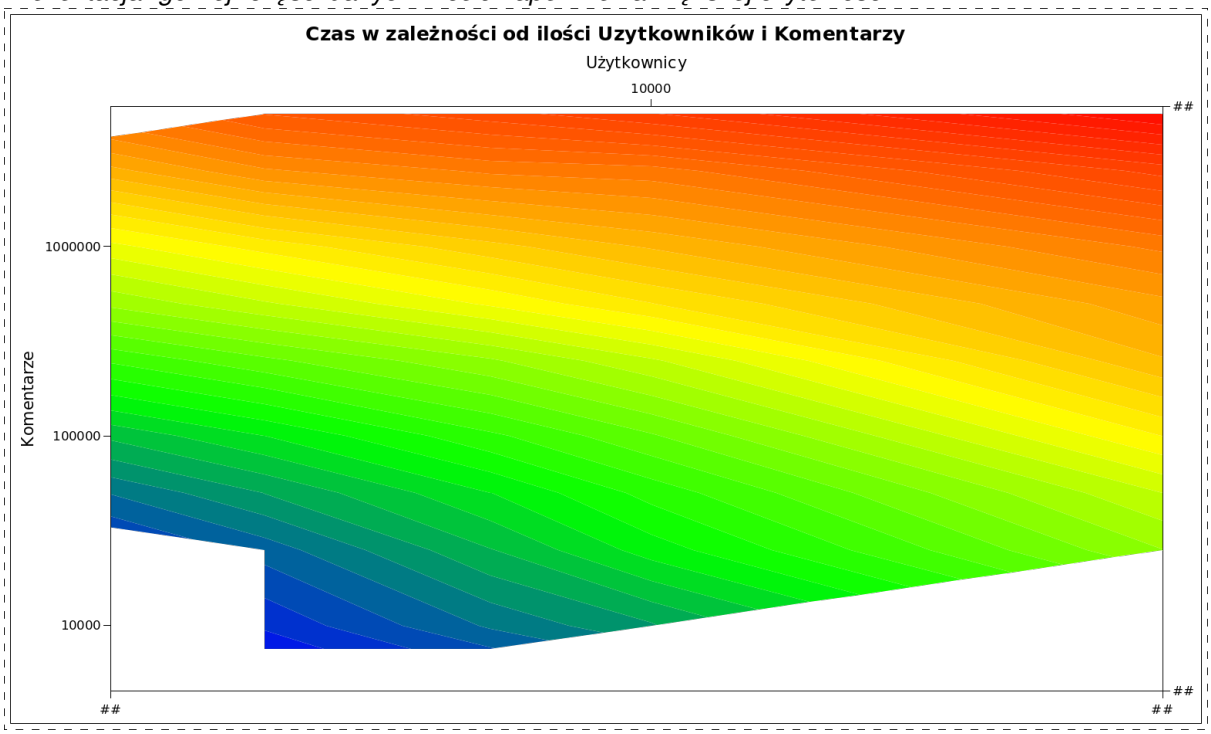

6.3 Analiza wyników pomiarów

Przed interpretacją wyników należy zwrócić uwagę na efekt mający wpływ na zmniejszenie czasu obliczeń. Generowania problemów nie uwzględnia tworzenia nieunikalnych połączeń pomiędzy użytkownikami [może wystąpić kilka połączeń pomiędzy 2] które jest niwelowane po wczytaniu problemu do algorytmu skutkując mniejszym rzeczywistym rozmiarem problemu.
Wyniki testów zostały poddane analizie w programie *gnumeric* czego efektem są powyższe wykresy. Ponadto trójki wartości *[liczba użytkowników][liczba komentarzy][czas]* zostały poddane regresji liniowej. Dla regresji wszystkich wartości współczynnik korelacji pomiędzy ilością komentarzy, a czasem *[miarą złożoności problemu]* wynosi : *0.93* co można uznać za złożoność *O(E)* względem liczby krawędzi *E*. Wniosek ten potwierdza obserwacja wykresu.
Dla liczności grupy sytuacja jest nieco bardziej złożona ponieważ korelacja dla całego zbioru wartości wynosi *0.66* co nie dowodzi zależności liniowej. Jednak obserwując wykres widzimy, że dla odpowiednio dużych wartości stopniowo wypłaszacza się i ma skośną asymptotę liniową.
Ponieważ zależność pomiędzy złożonością a *E* i *V* jest liniowa to wynikowa złożoność może przedstawiać się jako *O(V*E)* lub *O(V+E)*. Analiza z użyciem regresji liniowej dla 2 zmiennych, próbek o liczbie użytkowników większej od 250 daje zbieżność na poziomie *0.97*
Podsumowując: przeprowadzony eksperyment dowodzi, że zaproponowany algorytm ma pesymistyczna złożoność *O(V+E)* jednak obserwując można zauważyć, że w miarę wypełniania grafu dynamika wzrostu maleje. Ze względu na skończoną liczbę możliwych unikalnych połączeń czas wysyca się w miarę dążenia do grafu pełnego dwudzielnego. wszelkie zduplikowane połączenia śa pomijane w fazie ładowania problemu do programu.

6.4 Tabela zgodności z przewidywaniami

l.uzytkowników	*śr. komentarzy na użytkownika*	*l.komentarzy*	*wartość przewidziana*	*wartość pomiaru*	***pomiar/ przewidywanie***
5000	1.5	7500	702	390.351	0.556
5000	2	10000	711	398.638	0.561
2500	2	5000	330.5	190.315	0.576
25000	2	50000	3755	2606.098	0.694
10000	2.5	25000	1490	938.633	0.63
1000	2.5	2500	104	67.353	0.648
2500	3	7500	339.5	200.814	0.591
7500	3.33	25000	1127.5	696.972	0.618
750	3.33	2500	67.75	47.304	0.698
2500	4	10000	348.5	213.9	0.614
25000	4	100000	3935	3218.993	0.818
5000	5	25000	765	490.326	0.641
1000	5	5000	113	75.008	0.664
10000	5	50000	1580	1095.701	0.693
7500	6.67	50000	1217.5	830.098	0.682
750	6.67	5000	76.75	55.681	0.725
1000	7.5	7500	122	82.002	0.672
2500	10	25000	402.5	267.625	0.665
1000	10	10000	131	89.239	0.681
5000	10	50000	855	592.629	0.693
750	10	7500	85.75	62.96	0.734
10000	10	100000	1760	1356.721	0.771
25000	10	250000	4475	4659.737	1.041
750	13.33	10000	94.75	70.09	0.74
7500	13.33	100000	1397.5	1074.72	0.769
2500	20	50000	492.5	342.313	0.695
5000	20	100000	1035	804.445	0.777
25000	20	500000	5375	6124.138	1.139
1000	25	25000	185	129.983	0.703
10000	25	250000	2300	2031.328	0.883
750	33.33	25000	148.75	107.094	0.72
7500	33.33	250000	1937.5	1646.5	0.85
2500	40	100000	672.5	492.24	0.732
25000	40	1000000	7175	8378.315	1.168
1000	50	50000	275	183.739	0.668
5000	50	250000	1575	1309.985	0.832
10000	50	500000	3200	3161.038	0.988
750	66.67	50000	238.75	159.681	0.669
7500	66.67	500000	2837.5	2628.546	0.926
1000	100	100000	455	286.555	0.63
2500	100	250000	1212.5	891.067	0.735
5000	100	500000	2475	2163.041	0.874
10000	100	1000000	5000	4953.347	0.991
25000	100	2500000	12575	14595.775	1.161
750	133.33	100000	418.75	251.623	0.601
7500	133.33	1000000	4637.5	4323.744	0.932
2500	200	500000	2112.5	1476.193	0.699
5000	200	1000000	4275	3684.329	0.862
25000	200	5000000	21575	23649.72	1.096
10000	250	2500000	10400	9808.519	0.943